

AMAÇ

Bu çalışmada, şarapların fizikokimyasal özellikleri kullanılarak kalite tahmini yapılmış ve aynı zamanda bir şarabı “iyi” yapan fizikokimyasal özellikler incelenmiştir. Bu kapsamda, farklı makine öğrenmesi modelleri kurularak şarap kalitesinin tahmin edilebilirliği değerlendirilmiş; elde edilen modeller aracılığıyla değişkenlerin kalite üzerindeki göreceli etkileri analiz edilmiştir. Model performans metrikleri, hem tahmin başarısını değerlendirmek hem de elde edilen bulguların güvenilirliğini desteklemek amacıyla kullanılmıştır.

```
In [1]: import pandas as pd
import numpy as np
```

```
In [2]: data = pd.read_csv("winequality-red.csv")
data.head()
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5
1	7.8	0.88	0.00	2.6	0.098	25.0	67.0	0.9968	3.20	0.68	9.8	5
2	7.8	0.76	0.04	2.3	0.092	15.0	54.0	0.9970	3.26	0.65	9.8	5
3	11.2	0.28	0.56	1.9	0.075	17.0	60.0	0.9980	3.16	0.58	9.8	6
4	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5

```
In [3]: data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1599 entries, 0 to 1598
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   fixed acidity          1599 non-null   float64
1   volatile acidity       1599 non-null   float64
2   citric acid            1599 non-null   float64
3   residual sugar         1599 non-null   float64
4   chlorides              1599 non-null   float64
5   free sulfur dioxide    1599 non-null   float64
6   total sulfur dioxide   1599 non-null   float64
7   density                1599 non-null   float64
8   pH                    1599 non-null   float64
9   sulphates              1599 non-null   float64
10  alcohol                1599 non-null   float64
11  quality                 1599 non-null   int64
dtypes: float64(11), int64(1)
memory usage: 150.0 KB
```

```
In [4]: data.shape
```

Out[4]: (1599, 12)

Veri seti 1599 gözlem ve 12 değişkenden oluşmaktadır. Fizikokimyasal özellikleri temsil eden 11 değişken sayısal yapıdadır. Hedef değişken olan quality sütunu tamsayı tipinde ve sıralı kategorik bir yapıya sahiptir.

```
In [5]: #eksik veri yok
data.isnull().sum()
```

```
Out[5]: fixed acidity          0
volatile acidity              0
citric acid                   0
residual sugar                0
chlorides                     0
free sulfur dioxide           0
total sulfur dioxide          0
density                      0
pH                           0
sulphates                     0
alcohol                       0
quality                       0
dtype: int64
```

```
In [6]: data.duplicated().sum()
```

Out[6]: np.int64(240)

```
In [7]: data = data.drop_duplicates() #Tekrarlayan gözlemler veri setinden çıkarıldı
```

```
In [8]: data.describe()
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
count	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000	1359.000000
mean	8.310596	0.529478	0.272333	2.523400	0.088124	15.893304	46.825975	0.996709	3.309787	0.658705	10.432315	5.623000
std	1.736990	0.183031	0.195537	1.352314	0.049377	10.447270	33.408946	0.001869	0.155036	0.170667	1.082065	0.823000
min	4.600000	0.120000	0.000000	0.900000	0.012000	1.000000	6.000000	0.990070	2.740000	0.330000	8.400000	3.000000
25%	7.100000	0.390000	0.090000	1.900000	0.070000	7.000000	22.000000	0.995600	3.210000	0.550000	9.500000	5.000000
50%	7.900000	0.520000	0.260000	2.200000	0.079000	14.000000	38.000000	0.996700	3.310000	0.620000	10.200000	6.000000
75%	9.200000	0.640000	0.430000	2.600000	0.091000	21.000000	63.000000	0.997820	3.400000	0.730000	11.100000	6.000000
max	15.900000	1.580000	1.000000	15.500000	0.611000	72.000000	289.000000	1.003690	4.010000	2.000000	14.900000	8.000000

```
In [9]: outlier_ratio = {}

for col in data.select_dtypes(include=["float64", "int64"]).columns:
    Q1 = data[col].quantile(0.25)
    Q3 = data[col].quantile(0.75)
    IQR = Q3 - Q1

    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR

    ratio = ((data[col] < lower) | (data[col] > upper)).mean() * 100
    outlier_ratio[col] = round(ratio, 2)

pd.Series(outlier_ratio).sort_values(ascending=False)
```

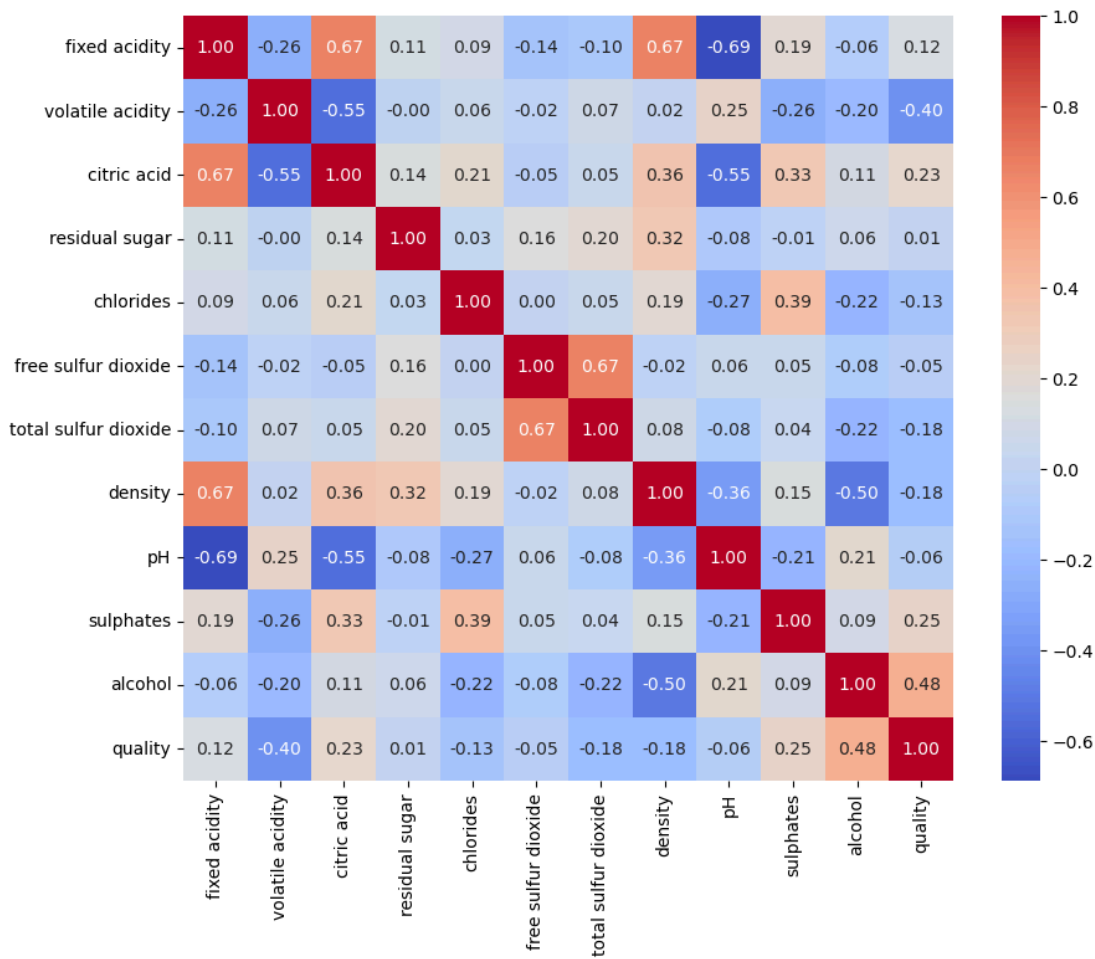
```
Out[9]: residual sugar      9.27
chlorides      6.40
sulphates      4.05
total sulfur dioxide  3.31
fixed acidity    3.02
density         2.58
pH             2.06
quality         1.99
free sulfur dioxide  1.91
volatile acidity  1.40
alcohol         0.88
citric acid     0.07
dtype: float64
```

Aykırı değer oranlarına bakıldığında, aykırı değerlerin en çok residual sugar ve chlorides değişkenlerinde görüldüğü, diğer değişkenlerde ise oranların düşük olduğu gözlemlenmiştir. Bu nedenle, bu aşamada aykırı değerler yalnızca tespit edilmiş, veri kaybını önlemek amacıyla herhangi bir çıkarma işlemi yapılmamıştır.

```
In [10]: import matplotlib.pyplot as plt
import seaborn as sns

corr = data.corr()

plt.figure(figsize=(10, 8))
sns.heatmap(corr, annot=True, fmt=".2f", cmap="coolwarm")
plt.show()
```



Korelasyon analizi, quality ile bazı değişkenler arasında doğrusal ilişkiler olduğunu göstermiştir. Alkol pozitif; volatile acidity ve total sulfur dioxide ise negatif yönde ilişki göstermektedir.

```
In [11]: (data["quality"].value_counts()).sort_index(ascending=True) #hedef değişken dağılımı
```

```
Out[11]: quality
3      10
4      53
5     577
6     535
7     167
8      17
Name: count, dtype: int64
```

Quality değişkeninin dağılımı dengesiz bir yapı göstermektedir. Bu çalışmada, analiz ve yorumlamayı sadeleştirmek amacıyla kalite puanı 6.5 ve üzeri olan şaraplar "iyi", diğerleri ise "iyi değil" olarak ikili sınıflandırma problemine dönüştürülmüştür.

```
In [12]: data["quality_class"] = (data["quality"] >= 6.5).astype(int)
```

```
In [13]: data["quality_class"].value_counts()
```

```
Out[13]: quality_class
0      1175
1       184
Name: count, dtype: int64
```

```
In [14]: X = data.drop(columns=["quality", "quality_class"])
y = data["quality_class"]
```

```
In [15]: from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)
```

RANDOM FOREST

```
In [16]: from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, recall_score, roc_auc_score, classification_report, confusion_matrix

rf = RandomForestClassifier(
    n_estimators=100,
    random_state=42
)

rf.fit(X_train, y_train)

y_pred = rf.predict(X_test)
y_proba = rf.predict_proba(X_test)[:, 1]
```

```
In [17]: acc_rf = accuracy_score(y_test, y_pred)
rec_rf = recall_score(y_test, y_pred)
auc_rf = roc_auc_score(y_test, y_proba)

print("Accuracy:", acc_rf)
print("Recall:", rec_rf)
print("AUC:", auc_rf)
print("\nClassification Report:\n", classification_report(y_test, y_pred))
print("Confusion Matrix:\n", confusion_matrix(y_test, y_pred))
```

```
Accuracy: 0.8933823529411765
Recall: 0.35135135135135137
AUC: 0.8622771707878092
```

```
Classification Report:
              precision    recall  f1-score   support


     0       0.91      0.98      0.94        235
     1       0.72      0.35      0.47         37

 accuracy          0.89          0.89          0.89          272
 macro avg         0.81          0.67          0.71          272
weighted avg         0.88          0.89          0.88          272
```

```
Confusion Matrix:
[[230   5]
 [ 24  13]]
```

```
In [18]: feature_importance = pd.Series(
    rf.feature_importances_,
    index=X_train.columns
).sort_values(ascending=False)

plt.figure(figsize=(8, 5))
sns.barplot(x=feature_importance, y=feature_importance.index)
plt.title("Random Forest Feature Importance")
plt.xlabel("Importance")
plt.ylabel("Feature")
plt.tight_layout()
plt.show()
```



Random Forest modeli yüksek AUC değeri ile şarap kalitesini ayırt edebilmiştir. Recall değerinin görece düşük olması sınıf dengesizliği ile ilişkilidir.

LOGISTIC REGRESSION

```
In [19]: from sklearn.model_selection import StratifiedKFold, cross_validate
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

pipe_lr = Pipeline([
    ("scaler", StandardScaler()),
    ("lr", LogisticRegression(max_iter=1000, random_state=42))
])

scoring = {
    "accuracy": "accuracy",
    "recall": "recall",
    "auc": "roc_auc"
}

cv_results = cross_validate(
    pipe_lr,
    X_train, y_train,
    cv=cv,
    scoring=scoring,
    return_train_score=False
)

print("CV Accuracy (mean):", np.mean(cv_results["test_accuracy"]))
print("CV Recall (mean):", np.mean(cv_results["test_recall"]))
print("CV AUC (mean):", np.mean(cv_results["test_auc"]))
```

CV Accuracy (mean): 0.8703124339407262
 CV Recall (mean): 0.2852873563218391
 CV AUC (mean): 0.8533761310833945

```
In [20]: pipe_lr_final = Pipeline([
    ("scaler", StandardScaler()),
    ("lr", LogisticRegression(max_iter=1000, random_state=42))
])

pipe_lr_final.fit(X_train, y_train)

y_pred_lr = pipe_lr_final.predict(X_test)
y_proba_lr = pipe_lr_final.predict_proba(X_test)[:, 1]

acc_lr = accuracy_score(y_test, y_pred_lr)
rec_lr = recall_score(y_test, y_pred_lr)
auc_lr = roc_auc_score(y_test, y_proba_lr)

print("Test Accuracy:", acc_lr)
print("Test Recall:", rec_lr)
print("Test AUC:", auc_lr)
print("\nClassification Report:\n", classification_report(y_test, y_pred_lr))
print("Confusion Matrix:\n", confusion_matrix(y_test, y_pred_lr))
```

Test Accuracy: 0.875
Test Recall: 0.24324324324326
Test AUC: 0.8860264519838988

```
Classification Report:
              precision    recall  f1-score   support

     0       0.89         0.97         0.93         235
     1       0.60         0.24         0.35          37

 accuracy          0.75         0.61         0.64         272
 macro avg          0.75         0.61         0.64         272
weighted avg          0.85         0.88         0.85         272
```

Confusion Matrix:
[[229 6]
 [28 9]]

```
In [21]: coef = pipe_lr_final.named_steps["lr"].coef_[0]
features = X_train.columns

coef_df = pd.Series(coef, index=features).sort_values(ascending=False)
coef_df
```

```
Out[21]: alcohol          0.900057
sulphates          0.541116
fixed acidity       0.380001
residual sugar      0.195311
citric acid        -0.047463
free sulfur dioxide -0.051454
pH                 -0.133652
density            -0.300335
total sulfur dioxide -0.337110
chlorides           -0.378406
volatile acidity    -0.593284
dtype: float64
```

Logistic Regression modeli test setinde yüksek AUC değeri elde etmiştir. Katsayılar, alcohol ve sulphates değişkenlerinin pozitif; volatile acidity değişkeninin ise negatif yönde etkili olduğunu göstermektedir.

GRADIENT BOOSTING

```
In [22]: from sklearn.ensemble import GradientBoostingClassifier

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

gb = GradientBoostingClassifier(random_state=42)

scoring = {"accuracy": "accuracy", "recall": "recall", "auc": "roc_auc"}

cv_results_gb = cross_validate(
    gb,
    X_train, y_train,
    cv=cv,
    scoring=scoring,
    return_train_score=False
)

print("GB CV Accuracy (mean):", np.mean(cv_results_gb["test_accuracy"]))
print("GB CV Recall (mean):", np.mean(cv_results_gb["test_recall"]))
print("GB CV AUC (mean):", np.mean(cv_results_gb["test_auc"]))
```

GB CV Accuracy (mean): 0.8711833594047267
GB CV Recall (mean): 0.3524137931034483
GB CV AUC (mean): 0.8551442895573491

```
In [23]: gb.fit(X_train, y_train)

y_pred_gb = gb.predict(X_test)
y_proba_gb = gb.predict_proba(X_test)[:, 1]

acc_gb = accuracy_score(y_test, y_pred_gb)
rec_gb = recall_score(y_test, y_pred_gb)
auc_gb = roc_auc_score(y_test, y_proba_gb)

print("GB Test Accuracy:", acc_gb)
print("GB Test Recall:", rec_gb)
print("GB Test AUC:", auc_gb)
print("\nClassification Report:\n", classification_report(y_test, y_pred_gb))
print("Confusion Matrix:\n", confusion_matrix(y_test, y_pred_gb))
```

GB Test Accuracy: 0.8713235294117647
GB Test Recall: 0.35135135135135137
GB Test AUC: 0.8912018401380104

```
Classification Report:
              precision    recall  f1-score   support

     0       0.90         0.95         0.93         235
     1       0.54         0.35         0.43          37


 accuracy          0.72         0.65         0.68         272
 macro avg          0.72         0.65         0.68         272
weighted avg          0.85         0.87         0.86         272
```

Confusion Matrix:
[[224 11]
 [24 13]]

```
In [24]: gb_imp = pd.Series(gb.feature_importances_, index=X_train.columns).sort_values(ascending=False)

plt.figure(figsize=(8, 5))
```

```
sns.barplot(x=gb_imp, y=gb_imp.index)
plt.title("Gradient Boosting Feature Importance")
plt.xlabel("Importance")
plt.ylabel("Feature")
plt.tight_layout()
plt.show()
```



Gradient Boosting modeli yüksek AUC değeri ile istikrarlı bir performans sergilemiştir. Recall değerinin Random Forest ile benzer seviyede olduğu görülmüştür.

```
In [25]: results = pd.DataFrame([
    {"Model": "Random Forest",
     "Accuracy": acc_rf,
     "Recall": rec_rf,
     "AUC": auc_rf},

    {"Model": "Logistic Regression",
     "Accuracy": acc_lr,
     "Recall": rec_lr,
     "AUC": auc_lr},

    {"Model": "Gradient Boosting",
     "Accuracy": acc_gb,
     "Recall": rec_gb,
     "AUC": auc_gb},

])

results
```

```
Out[25]:
```

	Model	Accuracy	Recall	AUC
0	Random Forest	0.893382	0.351351	0.862277
1	Logistic Regression	0.875000	0.243243	0.886026
2	Gradient Boosting	0.871324	0.351351	0.891202

SONUÇ

Random Forest, Logistic Regression ve Gradient Boosting modelleri benzer ve yüksek AUC değerleri elde ederek şarap kalitesinin anlamlı şekilde ayırt edilebildiğini göstermiştir. Ağaç tabanlı modellerin recall değerlerinin daha yüksek olması, iyi şarapları yakalama açısından daha başarılı olduklarını ortaya koymaktadır. Recall değerlerinin görece düşük kalması ise veri setindeki sınıf dengesizliği ve varsayılan karar eşiği ile ilişkilidir.

Model sonuçları birlikte değerlendirildiğinde, bir şarabın "iyi" olarak sınıflandırılmasında en belirleyici özelliğin yüksek alcohol oranı olduğu görülmüştür. Ayrıca sulphates değişkeni kaliteyi pozitif yönde etkilerken; yüksek volatile acidity, chlorides ve total sulfur dioxide seviyelerinin kalite üzerinde olumsuz etkisi bulunmaktadır. Farklı modellerde büyük ölçüde benzer değişkenlerin öne çıkması, elde edilen bulguların tutarlı olduğunu göstermektedir.